

Classificação Automática de Autos de Infração Ambiental utilizando Processamento de Linguagem Natural

Murilo Gemi De Carli¹, Elieus Floss¹

¹ Universidade Federal da Fronteira Sul (UFFS)

Abstract. *This work proposes the development of a solution for the automatic classification of environmental infraction notices using Natural Language Processing and Machine Learning techniques. Public data provided by the Brazilian Institute of Environment and Renewable Natural Resources (IBAMA) will be used to train and evaluate text classification models. The proposed solution aims to support the organization and analysis of environmental infraction records.*

Resumo. *Este trabalho propõe o desenvolvimento de uma solução para a classificação automática de autos de infração ambiental utilizando técnicas de Processamento de Linguagem Natural e Aprendizado de Máquina. Serão utilizados dados públicos disponibilizados pelo Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis (IBAMA) para o treinamento e avaliação de modelos de classificação textual. A solução proposta busca auxiliar na organização e análise de registros de infrações ambientais.*

1. Introdução

A fiscalização ambiental desempenha um papel importante na prevenção e repressão de práticas que causam danos ao meio ambiente. No Brasil, o Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis (IBAMA) atua na fiscalização ambiental federal em diferentes áreas, entre elas flora, fauna, pesca, atividades potencialmente poluidoras e patrimônio genético [IBAMA 2022].

Entre os dados disponibilizados publicamente pelo IBAMA encontra-se o conjunto de autos de infração ambiental, que possui abrangência nacional e registros históricos de ações de fiscalização. A base contém, entre seus atributos, a descrição textual do auto de infração, a descrição da infração e seu respectivo tipo, além de informações temporais e geográficas [IBAMA 2026a].

Essas características possibilitam a aplicação de técnicas de Processamento de Linguagem Natural (PLN) para analisar as descrições textuais presentes nos registros. O PLN reúne métodos computacionais destinados ao processamento, interpretação e análise da linguagem humana, sendo utilizado em diferentes tarefas, incluindo a classificação automática de textos.

No contexto da língua portuguesa, diferentes pesquisas têm investigado a aplicação de técnicas de PLN e aprendizado de máquina sobre textos produzidos em domínios específicos. Trabalhos relacionados ao domínio jurídico brasileiro, por exemplo, demonstram a possibilidade de utilização de modelos computacionais para classificação automática de documentos e descrições textuais [Polo et al. 2021, Noguti et al. 2024].

Diante desse contexto, este trabalho propõe o desenvolvimento de uma solução para a classificação automática de autos de infração ambiental a partir de suas descrições textuais. Para isso, serão utilizados dados públicos disponibilizados pelo IBAMA, técnicas de PLN e algoritmos de aprendizado de máquina. Ao final, pretende-se também desenvolver uma aplicação que permita inserir uma descrição textual e obter como resultado a categoria de infração prevista pelo modelo.

2. Problema

O registro de um auto de infração ambiental contém informações textuais que descrevem a conduta identificada durante uma ação de fiscalização. Na base pública disponibilizada pelo IBAMA, existem campos destinados à descrição do auto e à categorização da infração, possibilitando a utilização desses registros em tarefas de aprendizado supervisionado [IBAMA 2026a].

Considerando o grande volume histórico de registros e a existência de diferentes categorias de infrações, o processo de análise dessas informações pode se tornar complexo quando realizado manualmente. Técnicas de PLN e aprendizado de máquina podem ser utilizadas para identificar padrões presentes nas descrições e relacioná-los automaticamente às categorias existentes.

Dessa forma, o problema de pesquisa deste trabalho é definido pela seguinte questão:

É possível classificar automaticamente autos de infração ambiental em suas respectivas categorias utilizando as informações presentes em suas descrições textuais?

Neste trabalho, pretende-se utilizar a descrição textual dos autos como principal variável de entrada e as categorias existentes na base do IBAMA como referência para o processo de classificação. A definição final das classes e a necessidade de possíveis agrupamentos serão determinadas posteriormente a partir da análise exploratória dos dados.

3. Objetivos

3.1. Objetivo Geral

Desenvolver e avaliar uma solução baseada em Processamento de Linguagem Natural e aprendizado de máquina capaz de classificar automaticamente descrições textuais de autos de infração ambiental em suas respectivas categorias.

3.2. Objetivos Específicos

Os objetivos específicos deste trabalho são:

- obter e analisar a base pública de autos de infração ambiental disponibilizada pelo IBAMA;
- realizar o pré-processamento das descrições textuais utilizadas no projeto;
- identificar e analisar as categorias de infração existentes na base de dados;
- desenvolver diferentes modelos para classificação automática dos textos;
- comparar o desempenho dos modelos utilizando métricas adequadas para problemas de classificação;

- selecionar o modelo com melhor desempenho para utilização na solução;
- desenvolver uma aplicação web que permita classificar novas descrições de infrações ambientais;
- avaliar as limitações e possibilidades de utilização da abordagem proposta.

4. Justificativa

O IBAMA disponibiliza publicamente dados referentes aos autos de infração ambiental registrados em seus sistemas. Esse conjunto de dados apresenta abrangência nacional e contém informações estruturadas associadas às descrições textuais das infrações [IBAMA 2026a]. A disponibilidade dessas informações possibilita a realização de estudos utilizando dados reais sem a necessidade de construção manual de uma base de dados desde o início.

A utilização de dados também possui relevância para o planejamento e a tomada de decisões relacionadas à fiscalização ambiental. O IBAMA desenvolve ações de planejamento e análise de informações ambientais, incluindo iniciativas como o Plano Nacional Anual de Proteção Ambiental e a elaboração de diagnósticos de delitos ambientais [IBAMA 2026b].

No contexto brasileiro, pesquisas já investigaram técnicas de PLN aplicadas a textos jurídicos e administrativos. O trabalho LegalNLP [Polo et al. 2021] apresenta recursos e modelos direcionados ao processamento de linguagem jurídica em português brasileiro. Da mesma forma, estratégias de classificação automática de descrições textuais relacionadas a demandas jurídicas também têm sido investigadas [Noguti et al. 2024].

Dessa forma, este projeto se justifica tanto pela disponibilidade de dados públicos reais quanto pelo potencial de utilização de técnicas de PLN para transformar descrições textuais em informações estruturadas. Uma ferramenta capaz de sugerir automaticamente a categoria de uma infração pode contribuir para a organização e análise de registros ambientais, além de servir como apoio para pesquisadores, analistas e gestores.

Além disso, o desenvolvimento do projeto possibilita avaliar empiricamente o desempenho e as limitações de diferentes técnicas de classificação textual quando aplicadas a registros brasileiros de fiscalização ambiental.

Referências

- IBAMA (2022). O que é fiscalização ambiental. <https://www.gov.br/ibama/pt-br/assuntos/fiscalizacao-e-protecao-ambiental/fiscalizacao-ambiental/o-que-e-fiscalizacao>. Atualizado em 3 jul. 2026. Acesso em: 11 ago. 2026.
- IBAMA (2026a). Fiscalização – auto de infração. <https://dadosabertos.ibama.gov.br/dataset/fiscalizacao-auto-de-infracao>. Portal de Dados Abertos do IBAMA. Acesso em: 11 ago. 2026.
- IBAMA (2026b). Plano nacional anual de proteção ambiental (pnapa) 2026. <https://www.gov.br/ibama/pt-br/assuntos/fiscalizacao-e-protecao-ambiental/fiscalizacao-ambiental/publicacoes>. Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis. Acesso em: 11 ago. 2026.

- Noguti, M. Y., Vellasques, E., and Oliveira, L. E. S. (2024). A small claims court for the nlp: Judging legal text classification strategies with small datasets. *arXiv preprint arXiv:2409.05972*.
- Polo, F. M., Mendonça, G. C. F., Parreira, K. C. J., Gianvechio, L., Cordeiro, P., Ferreira, J. B., Lima, L. M. P. d., Maia, A. C. d. A., and Vicente, R. (2021). Legalnlp: Natural language processing methods for the brazilian legal language. *arXiv preprint arXiv:2110.15709*.